

1. Введение и постановка задачи

Задача проекта — предсказание рейтинга задач Codeforces по их метаданным. В качестве входных данных используются название задачи, теги, текст условия и числовые характеристики, связанные с задачей.

Рейтинг отражает сложность задачи, поэтому задача формулируется как регрессия.

Практическая мотивация связана с возможностью оценки сложности задач при составлении контестов. Такая модель может использоваться авторами задач для предварительной проверки корректности выбранного рейтинга.

2. Поиск и описание данных

Данные собраны с платформы Codeforces с использованием API и парсинга страниц задач.

Общий объем после очистки составляет около 1500 задач. При сборе данных использовалась задержка запросов ~0.5 секунды для соблюдения ограничений API.

Распределение рейтингов охватывает диапазон примерно от 800 до 3500 и не демонстрирует выраженного перекоса.

Из рассмотрения исключены признаки, которые формируются после решения задачи пользователями, чтобы избежать утечки данных.

3. Обработка и подготовка данных

Данные в исходном виде не содержали существенных пропусков или ошибок.

Были сформированы следующие признаки:

- числовые признаки: количество решений, логарифм количества решений, длина текста условия, количество слов в условии, длина названия, количество тегов
- бинарные признаки: наличие математических выражений в тексте
- категориальные признаки: топ-10 наиболее частотных тегов с one-hot кодированием

Дополнительно выполнено логарифмирование признака `solvedCount` для снижения асимметрии распределения.

Разбиение выборки выполнено по контестам, что позволяет избежать утечки информации между обучающей и тестовой выборками, так как задачи одного контеста обладают схожими характеристиками.

4. Baseline-модель

В качестве базовой модели использовано константное предсказание (медиана рейтинга обучающей выборки).

Полученное значение MAE составляет примерно **310**.

Данный baseline используется как точка отсчёта для оценки качества более сложных моделей.

5. Эксперименты

Проведены эксперименты с различными типами моделей и наборами признаков.

Гипотеза 1

Текстовые признаки содержат информацию о сложности задачи.

Проверка: добавление признаков, основанных на длине и структуре текста условия.

Результат: снижение MAE относительно baseline.

Гипотеза 2

Нелинейные модели превосходят линейные модели на данной задаче.

Проверка: сравнение Ridge Regression, Random Forest и XGBoost.

Результат: деревья решений показывают более низкую ошибку.

Гипотеза 3

Ансамбли моделей дают более стабильное качество.

Проверка: объединение Ridge, Random Forest и XGBoost в Voting Ensemble.

Результат: достижение минимального значения MAE.

6. Финальная модель и интерпретируемость

В качестве финальной модели выбран Voting Ensemble, включающий Ridge Regression, Random Forest и XGBoost.

Линейная модель стабилизирует предсказания, а ансамблевые деревья позволяют учитывать нелинейные зависимости.

Наиболее значимыми признаками оказались:

- признаки, связанные с текстом условия (длина, структура)
- категориальные признаки тегов
- количество решений задачи (`solvedCount`)

Наибольшие ошибки наблюдаются на задачах с нестандартным соотношением сложности и рейтинга, а также на задачах с исторически смещённой оценкой.

7. Деплой

Реализовано веб-приложение на FastAPI.

Сервис принимает признаки задачи и возвращает предсказанный рейтинг.

Реализована валидация входных данных и загрузка предобученной модели из сериализованного файла.

Приложение содержит Swagger-интерфейс для тестирования эндпоинтов.

Развёртывание выполнено в локальной среде.

8. Заключение и выводы

Результаты показывают, что рейтинг задач Codeforces может быть достаточно точно приближен на основе метаданных задачи.

Наибольший вклад в качество вносят текстовые признаки и теговая информация.

Ансамблевые модели обеспечивают более устойчивые предсказания по сравнению с отдельными моделями.

Дальнейшее улучшение качества возможно за счёт увеличения объёма данных и применения моделей, учитывающих семантику текста (например, трансформеров).